

BT GÖRÜNTÜLERİNDE AKUT İSKEMİK İNME LEZYONU SEGMENTASYONU İÇİN UNET MODELİNİN PARÇACIK SÜRÜ OPTİMİZASYONU

İnme, dünya çapında üçüncü en büyük ölüm nedeni ve kazanılmış sakatlığın en büyük kaynağıdır [1]. Bu duruma, beynin bir bölgesindeki ölümcül derecede düşük kan akışı neden olur. İnme lezyonu başlangıçta iki alana ayrılır: Geri döndürülemez şekilde hasar görmüş dokudan oluşan enfarktüs çekirdeği ve kan akışı yeniden sağlandığında hala geri kazanılabilen risk altındaki doku olan penumbra. Akut inme veya penumbranın lokalizasyonu ve nicelleştirilmesi, farklı tedavilerle kurtarılabilir doku miktarının değerlendirilmesine ve daha bilinçli kararlar alınmasına yardımcı olabileceğinden, klinik açıdan büyük ilgi görmektedir.

Kontrastsız bilgisayarlı tomografi (BT) görüntüleme hızlı, ucuz, her yerde bulunduğu için ve klinisyenler tarafından akut iskemik inmenin triyaj, tanı ve tedavi değerlendirmesi için temel bir ilk adım olarak kullanılmaktadır [2].

Akut inme tespiti ve özel olarak BT görüntülerini kullanan segmentasyon için denetimli yöntemler üzerinde yapılan ilk çalışmalar, doku ve yoğunluktan yararlanan el yapımı özelliklere dayanıyordu [3], [4], [5], [6]

Evrişimsel Sinir Ağları (CNN) ile ilgili son gelişmeler, biyomedikal segmentasyonlarında mevcut olan üstün sonuçlara sahip yöntemlerin ortaya çıkmasına neden olmuştur. MR görüntülerinden inme lezyonu segmentasyonu için en son yöntemlerde de görülebilir. Daha spesifik olarak, U-Net'e dayalı U-şekilli mimariler yoğun semantik segmentasyon için çok uygundur. [7].

CNN'lerde, katmanlar, verilen herhangi bir katmanın çıktısı bir sonraki katmanın girdisi olacak şekildedir.

Bu çalışmada, akut iskemik inme lezyonu segmentasyonu performansını iyileştirmek için Parçacık Sürü Optimizasyonu (PSO) ile UNET modeli birleştiren yeni bir derin öğrenme mimarisi, yani PSO-UNET önerilmiştir.. UNET, biyomedikal görüntü segmentasyonu için tasarlanmış evrişimsel bir ağıdır [7]. Mimarisi simetriktir ve bir daralan yol ve bir genişleyen yol olmak üzere iki ana bölümden oluşur. Orijinal UNET simetrik bir mimariye sahip olduğundan, bu da genişleme yolunun büzülme yolunu izleyerek oluşturulduğu anlamına gelir., Unet modelinin doğruluğunu artırma PSO algoritması tarafından gerçekleştirilir.

Bu çalışmada Unet Mimarisinin iskemik inme lezyonu segmentasyonu performansını iyileştirmek için Parçacık Sürü Optimizasyonu (PSO) ile UNET'i birleştiren yeni bir model önerilmiştir. Model güncellemeleri için ağırlıklar yerine zar katsayısı(dice coef) ve kayıp gibi puanları toplayan yeni bir model oluşturulmuştur.

1. Kullanılan Algoritmaların Arka Planı


1.1. UNET Algoritması ve Mimarisi

UNET'in mimarisi simetriktir ve bir daralan yol ve genişleyen bir yol olmak üzere iki ana bölümden oluşur [7].CNN'nin sınıflandırma problemi için doğruluk(accuracy) puanı kriter olarak kabul edilirken, anlamsal bölütlemenin en önemli kriteri zar katsayısı (dice coef)'dır.

Mimarinin ilk yarısı, sözleşme yoludur (Şekil 1) (kodlayıcı). Genellikle, iki 3×3 2D evrişimin tekrarlanan dizisinden oluşan CNN mimarisidir.. Evrişim katmanlarının işlevi, görüntü boyutunu küçültmenin yanı sıra, çekirdek ile eleman bazında çarpma uygulayarak alanlardaki tüm komşu piksel bilgilerini tek bir piksele getirmektir. Aşırı uyum probleminden kaçınmak ve bir optimizasyon algoritmasının performansını iyileştirmek için, ReLU aktivasyonları ve toplu normalleştirme bu evrişimlerden hemen sonra eklenir. Evrişimin genel matematiksel ifadesi aşağıda açıklanmıştır.

$$G(x, y) = \omega * f(x, y)$$

$F(x, y)$ orijinal görüntüdür, ω çekirdek ve $G(x, y)$ evrişimsel hesaplamayı gerçekleştirdikten sonra ki çıktı görüntüsüdür.



Şekil 1. Unet Mimarisi

Genişleyen yol (kod çözücü), mimari diyagramın ikinci yarısıdır. Sözleşme yolundan karşılık gelen bir katman , toplu normalleştirme ve ReLU aktivasyonu tarafından takip edilen iki 3×3 2D evrişim ile özellik haritasının bir birleşimi vardır [7]. Birleştirme prosedürünün temel amacı, her evrişim katmanından sonra kenar piksellerinin kaybolması nedeniyle yerleştirme bilgisi sağlamaktır. Son katman, istenen sayıda sınıfla (maske görüntüleri) nihai özellik haritasını eşlemek için kullanılan evrişimdir.

1.2. Parçacık Sürü Optimizasyonu

Metasezgisel optimizasyon algoritması olan PSO, 1995 yılında Kennedy ve Eberhart tarafından geliştirilmiştir [8]. Algoritma, doğadaki kuş ve balık sürülerinden ilham alan algoritmadır ve çok değişkeni aynı anda optimize eder. PSO algoritması, kolay uygulama, ölçeklenebilirlik, sağlamlık, hızlı yakınsama gibi avantajlara sahiptir. Algoritma, optimizasyon için çok sayıda yineleme gerektiren olasılıksal bir yaklaşım kullanır.

PSO bileşenleri sürü ve parçacıklar olarak ikiye ayrılabilir. Bir sürü, bir dizi parçacıktan oluşur. Her parçacık, soruna olası bir çözümü temsil eder. Her parçacığın bir sonraki adım için bir konumu ve hızı *vardır*. Küresel optimal değeri bulmak için parçacıklar adım adım birbirleriyle iletişim kurar ve kendi bilgilerini paylaşırlar.

Bir parçacığın çözümü aradığı süre boyunca kendisinin çözüme en çok yaklaştığı, o andaki en iyi durumuna **pbest** denirken, tüm sürüde tüm arama boyunca çözüme en çok yaklaşan parçacığın o andaki durumuna ise **gbest** denir.

Parçacıkları değişim hızı aşağıdaki denklem kullanılarak hesaplanır.

$$v_{i+1} = v_i + c_1 * rand_1 * (pbest - x) + c_2 * rand_2 * (gbest - x)$$

Bu formül sayesinde parçacık kendi en iyi çözümüne ve global en iyi çözüme yönelir. Bu da parçacığı çözümü en iyi parçacığın ve kendi en iyi durumunun yakınlarında aramaya iter.

2. Malzemeler

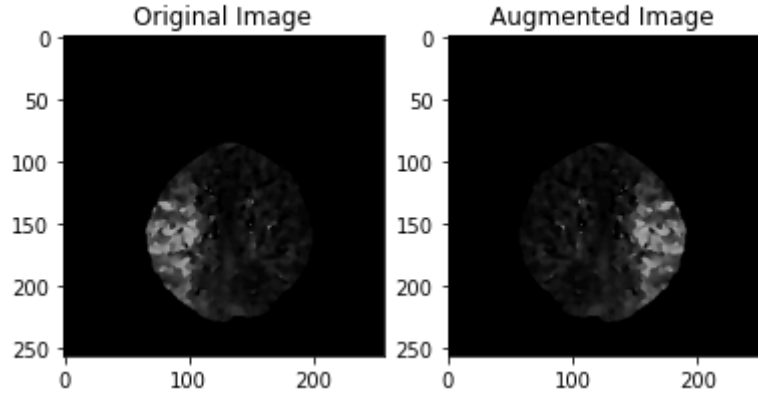
2.1. Veri

ISLES 2018 yarışma veri seti, akut BT taramalarından inme lezyon çekirdeğinin segmentasyonunu için, inme başlangıcından sonraki 8 saat içinde alınan verilerden oluşmaktadır. Sağlanan veri seti 94 etiketli eğitim görüntüsü ve 62 etiketsiz test görüntüsü içermektedir. Her vaka için bir CT taraması, ham bir CT perfüzyon zaman serisi (CT-PWI) ve dört türetilmiş perfüzyon haritası (CBF, CBV, MTT ve Tmax) sağlamaktadır. Görüntüler, hastaya bağlı olarak 2 ila 22 arasında değişen, 5 mm aralıklı ve 256×256 çözünürlüğe sahip değişken sayıda eksenel dilimli levhalar olarak elde edilmiştir.


3.2. Ön İşleme

Sağlanan BT görüntülerinden, ham CT-PWI zaman serilerini atlayarak yalnızca CT ve dört türetilmiş CT perfüzyon haritaları (CBF, CBV, MTT ve Tmax) kullanılmıştır.

Beyin yarıkürelerinin simetrisinden yararlanılarak veri çoğaltma işlemi gerçekleştirilmiştir. Tipik olarak beyin sadece bir yarım küresi felçten etkilendiğinden, beyin orta sagittal simetrisi, her iki yarım küre arasındaki farklılıkları değerlendirmek ve lezyonu daha doğru bir şekilde bulmak için kullanılmıştır.. Bu şekilde iki yarım kürenin, aynı mekansal konumundan gelen bilgileri içermektedir. Simetriği alınan orjinal görüntü ve maske Şekil 2. ve Şekil 3.'te verilmiştir.



Şekil 2.



Şekil 3.

3.Yöntem

Bu çalışmada, her iterasyon sonucunda eğitilen modellerin yalnızca en iyi zar katsayı ve kayıp değerini sağlayan ağırlıklarını alınır. Böylece tüm model ağırlıklarını bir sonraki iterasyonda iletmesi gerekmez. En iyi puan, her parçacığın üzerinde yapılan eğitimden sonra elde edilen en düşük kayıp değeridir. PSO-UNET, pbest ve gbest değişkenleri aracılığıyla en iyi modeli tanımlar ve en iyi modelin ağırlıklarını hız(V) değerini kullanarak günceller.

1. function TRAIN

1. initialize w_0 , pbest, gbest, gid
3. for each round $t=1,2,\dots$ do
 4. for each particle k in parallel do
 5. pbest \leftarrow ParticleUpdate(k, w_{gidt})
 6. if gbest > pbest then
 7. gbest \leftarrow pbest
 8. gid $\leftarrow k$
9. $w_{t+1} \leftarrow$ GetBestModel(gid)

10. function PARTICLEUPDATE(k, w_{gidt})

11. initialize $V, w, w_{pbest}, \alpha, c_1, c_2$

12. $\beta \leftarrow$ (split p_k into batches of size B)

13. **for** each weight layer $l=1,2,\dots$ **do**

14. $V_l \leftarrow \alpha \cdot V_l + c_1 \cdot \text{rand} \cdot w_{pbest} - V_l + c_2 \cdot \text{rand} \cdot w_{gbest} - V_l$

15. $w \leftarrow w + V$

16. **for** each particle epoch i from 1 to E **do**

17. **for** batch $b \in B$ **do**

18. $w \leftarrow w - \eta \nabla l(w; b)$

19. **return** $pbest$

20. function GETBESTMODEL(gid)

21. request to **particle**(gid)

22. receive w from **particle**

23. **return** w

23:

Tura katılan parçacıklar 4. adımda seçilir. 5. adımda parçacıktan ağırlık almadan yalnızca $pbest$ değerini alır. Toplananlar arasında minimum $pbest$ değerine sahip parçacığı bulma işlemi, 6-8 adımda yürütülür. function TRAIN PSO'yu uygulayan Uneti ilerletir. 13–14 arasındaki satırlar, önceki adımda kullanılan Değişken V 'yi, parçacık tarafından tutulan w_{pbest} 'in optimal değerini ve sunucuya alınan w_{gbest} değerini hesaplar. Bu işlem her eğitim ağırlığı için gerçekleştirilir. Ardından, Satır 15'e kadar geçerli turda kullanılacak w 'yi hesaplamak için değişken V önceki turdan w 'ye eklenir. Bundan sonra, eğitimi Satır 16–18 boyunca parçacık epoch sayısı kadar tamamlar. function GetBestModel eğitimdeki en iyi puana sahip parçacıktan modeli isteyen işlevdir (Satır 20–23).

4. Sonuç

Bu çalışmada Unet modelinin başarımlar değeri %59 kayıp değeri ise %38 şeklindedir. PSO-UNET algoritması ise %77 başarımlar ve %22 kayıp değerine sahiptir.

KAYNAKÇA

- [1] Sudlow C.L., Warlow C.P.
Comparable studies of the incidence of stroke and its pathological types: Results from an international collaboration. International stroke incidence collaboration. Stroke, 28 (3) (1997), pp. 491-499
- [2] Lev Michael H., Farkas Jeffrey, Gemmete Joseph J., Hossain Syeda T., Hunter George J., Koroshetz Walter J., Gonzalez R. Gilberto
Acute stroke: Improved nonenhanced CT detection—Benefits of soft-copy

interpretation by using variable window width and center level settings
Radiology, 213 (1) (1999), pp. 150-155, [10.1148/radiology.213.1.r99oc10150](https://doi.org/10.1148/radiology.213.1.r99oc10150)

- [3] Ušinskas Andrius, Dobrovolskis Romualdas, Tomandl Bernd F.
Ischemic stroke segmentation on CT images using joint features
Informatica, 15 (2) (2004), pp. 283-290
- [4] M. Chawla, S. Sharma, J. Sivaswamy, L.T. Kishore, A method for automatic
detection and classification of stroke from brain CT images, in: 2009 Annual
International Conference of the IEEE Engineering in Medicine and Biology
Society, 2009, pp. 3581–3584, <http://dx.doi.org/10.1109/IEMBS.2009.5335289>.
- [5] Tang Fuk-hay, Ng Douglas K.S., Chow Daniel H.K.
An image feature approach for computer-aided detection of ischemic stroke
Comput. Biol. Med., 41 (7) (2011), pp. 529-536,
[10.1016/J.COMPBIOMED.2011.05.001](https://doi.org/10.1016/J.COMPBIOMED.2011.05.001)
- [6] Hema Rajini N., Bhavani R.
Computer aided detection of ischemic stroke using segmentation and texture features
Measurement, 46 (6) (2013), pp. 1865-1874,
[10.1016/J.MEASUREMENT.2013.01.010](https://doi.org/10.1016/J.MEASUREMENT.2013.01.010)
- [7] Ronneberger, O., Fischer, P., & Brox, T. (2015, October). U-net: Convolutional
networks for biomedical image segmentation. In *International Conference on Medical
image computing and computer-assisted intervention* (pp. 234-241). Springer, Cham.
- [8] Chen, Y.; Sun, X.; Jin, Y. Communication-Efficient Federated Deep Learning With
Layerwise Asynchronous Model Update and Temporally Weighted Aggregation. *IEEE
Trans. Neural Netw. Learn. Syst.* **2020**, *31*, 4229–4238